2.6. Обработка табличной информации. Pandas для обработки результатов сканирования безопасности

2. Файлы, данные, простая обработка и визуализация

В этом уроке

- Узнаем как работать с таблицами
- Научимся делать это быстрее и эффективнее
- Разберёмся что такое pandas

Что такое pandas?

Pandas - это библиотека Python для удобной работы с табличными данными

Если нужно обрабатывать данные в виде таблиц (как в Excel), то Pandas - это идеальный инструмент. Он позволяет:

- Загружать данные из CSV, Excel, SQL и других источников.
- Чистить данные (удалять пропуски, исправлять ошибки).
- Анализировать (считать статистику, группировать, фильтровать).
- Сохранять обработанные данные в разные форматы.

Что такое pandas?

Series (Серия)

Это один столбец данных с метками (как именованный список)

```
import pandas as pd

temperatures = pd.Series([25, 28, 23, 30], name="Температура")
print(temperatures)
```

```
0    25
1    28
2    23
3    30
Name: Температура, dtype: int64
```

Что такое pandas?

DataFrame (Таблица данных)

Это таблица с несколькими столбцами, как в Excel.

```
data = {
    "Город": ["Москва", "Санкт-Петербург", "Казань"],
    "Население (млн)": [12.6, 5.4, 1.3],
    "Год основания": [1147, 1703, 1005]
}

df = pd.DataFrame(data)
print(df)
```

	Город	Население (млн)	Год основания
0	Москва	12.6	1147
1	Санкт-Петербург	5.4	1703
2	Казань	1.3	1005

Чтение файлов

Чтение csv- и excel-файлов

```
# Из CSV
df = pd.read_csv("data.csv")

# Из Excel
df = pd.read_excel("data.xlsx")
```

Просмотр данных

```
df.head(3)  # первые 3 строки
df.tail(2)  # последние 2 строки
df.info()   # информация о данных (типы столбцов, пропуски)
df.describe()  # статистика (среднее, мин, макс и т. д.)
```

Выбор данных

```
# Выбор столбца
df["Город"]           # как словарь
df.Город              # как атрибут (только если название без пробелов)

# Выбор строк по условию
df[df["Население (млн)"] > 5]  # города с населением > 5 млн

# Выбор по индексу
df.iloc[0]    # первая строка
df.loc[0, "Город"]  # значение в строке 0, столбце "Город"
```

Выбор данных

```
# Выбор столбца
df["Город"]           # как словарь
df.Город              # как атрибут (только если название без пробелов)

# Выбор строк по условию
df[df["Население (млн)"] > 5]  # города с населением > 5 млн

# Выбор по индексу
df.iloc[0]    # первая строка
df.loc[0, "Город"]  # значение в строке 0, столбце "Город"
```

Фильтрация и сортировка

```
# Фильтр
filtered_df = df[df["Год основания"] < 1500]

# Сортировка
df.sort_values("Население (млн)", ascending=False)
```

Добавление и удаление данных

```
# Новый столбец
df["Регион"] = ["Центр", "Северо-Запад", "Поволжье"]

# Удаление столбца
df.drop("Год основания", axis=1, inplace=True)
```

Обработка пропусков

```
# Удаление строк с пропусками
df.dropna()

# Заполнение пропусков
df.fillna(0)
```

Группировка и агрегация

```
# Считаем среднее население по регионам
df.groupby("Регион")["Население (млн)"].mean()
```

Сохранение данных

```
df.to_csv("new_data.csv", index=False)
df.to_excel("output.xlsx")
```

Итоги урока

- Узнали как работать с таблицами
- Разобрались что такое pandas и dataframe